

Relazione Big Data

Progetto n. 9: Hotel Reviews

Giuseppe Pasquale Caligiure - Mat. 280867

Febbraio 2026

Indice

1 Presentazione del Progetto	2
1.1 Contesto di lavoro e obiettivi Realizzati	2
1.2 Architettura Frontend/Backend	2
1.3 Tecnologie Utilizzate e Requisiti	2
1.4 Logica di Funzionamento	3
2 Descrizione del Dataset Hotel_Reviews	3
2.1 Campi del Dataset	3
3 Descrizione delle Query Implementate	4
3.1 Trend Recensioni (Time Series)	4
3.2 Analisi Influenza Tag	6
3.3 Analisi Bias Nazionalità	8
3.4 Analisi Competitività Locale	10
3.5 Segmentazione Hotel (K-Means Clustering)	12
3.6 Migliori Hotel per Nazione	15
3.7 Locals vs Tourists - Preferenze e distribuzione clienti	17
3.8 Analisi Stagionale & Target	20
3.9 Analisi Durata Soggiorno	22
3.10 Analisi Esperienza Recensore	24
4 Conclusioni Finali	26
4.1 User Interface	26
4.2 Analisi dei dati	26
4.3 Possibili Sviluppi Futuri	26

1 Presentazione del Progetto

1.1 Contesto di lavoro e obiettivi Realizzati

Il presente progetto è stato realizzato lavorando sul dataset “Hotel Reviews”, contenente oltre 515.000 recensioni di alberghi di lusso europei. L'applicativo realizzato consente di effettuare interrogazioni aggregate sul dataset, con l'obiettivo di estrarre insight significativi dai dati. Sfruttando le potenzialità di elaborazione distribuita offerte dal framework Spark, sono stati realizzati diversi moduli di analisi che consentono di rilevare aspetti temporali, testuali, geospaziali e comportamentali nelle recensioni del dataset. Gli obiettivi principali raggiunti includono:

- Identificazione dei trend di gradimento degli hotel nel tempo.
- Analisi dell'influenza di specifici tag (caratteristiche del soggiorno) sul punteggio finale.
- Segmentazione geografica e analisi della competitività locale.
- Profilazione degli hotel tramite algoritmi di Machine Learning (Clustering).
- Studio delle preferenze in base alla nazionalità e tipologia di viaggiatore.

1.2 Architettura Frontend/Backend

L'applicazione è stata realizzata seguendo una logica Frontend/Backend:

- **Backend (Spark):** Il file `queries.py` contiene la logica di lavoro. Ogni funzione implementa una diversa analisi dei dati, ma tutte rispettano il seguente schema: accetta un DataFrame Spark in input e restituisce un DataFrame Spark trasformato con i risultati.
- **Frontend (Streamlit):** Il file `app.py` gestisce l'interfaccia utente. All'avvio inizializza una `SparkSession` (cachata per efficienza) e carica il dataset. Quando l'utente seleziona un'analisi, il frontend invoca la funzione corrispondente dal backend, converte i risultati aggregati (di dimensioni ridotte) in Pandas DataFrame e li visualizza tramite grafici e tavole.

1.3 Tecnologie Utilizzate e Requisti

Il progetto è stato sviluppato in Python, utilizzando il framework di Spark per eseguire interrogazioni in maniera scalabile e distribuita.

- **Linguaggio:** Python 3.11. (il progetto è stato testato con Python 3.11.9)
- **Backend: Apache Spark** (PySpark) per l'elaborazione parallela e distribuita dei dati. In particolare sono stati utilizzati DataFrame Spark, Spark SQL, Window Functions e User Defined Functions (UDF).
- **Machine Learning:** **Spark MLlib** per operazioni di clustering (K-Means) e **Scikit-learn** per regressioni lineari all'interno di UDF pandas.
- **Frontend:** **Streamlit** per la creazione di una web-app interattiva che permette all'utente di eseguire query e filtrare risultati.
- **Visualizzazione:** **Altair**, **PyDeck** e **Pandas** per la creazione di grafici interattivi e mappe geospaziali.
- **Gestione Dipendenze Windows:** Winutils e Hadoop per l'esecuzione locale su ambiente Windows.

1.4 Logica di Funzionamento

1. L'utente avvia l'applicazione tramite script batch (`RUN_APP_Hotel_Reviews.bat`) o comando Streamlit (`python -m streamlit run app.py`).
2. L'app si avvia automaticamente in una finestra del browser predefinito del dispositivo in uso, ma è anche raggiungibile da altri dispositivi (pc, tablet, smartphone) collegati sulla stessa rete locale, tramite gli indirizzi specificati nel terminale (Figura 1).

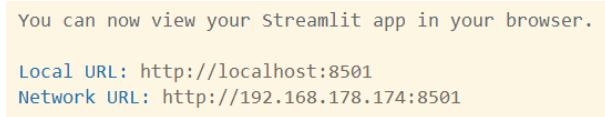


Figura 1: URL della web-app

3. Dopo il caricamento iniziale del dataset in memoria (DataFrame Spark), tramite una sidebar laterale è possibile selezionare una delle query disponibili.
4. Ogni query espone parametri specifici (es. numero minimo di recensioni, raggio in km) modificabili tramite slider o input box. L'esecuzione della query avviene on-demand sfruttando il motore Spark. I risultati vengono visualizzati in-app tramite grafici, tavole e mappe interattive.

2 Descrizione del Dataset Hotel_Reviews

Il dataset utilizzato è `Hotel_Reviews.csv` (reperibile su: <https://www.kaggle.com/datasets/jiashenliu/515k-hotel-reviews-data-in-europe>). Questo archivio contiene oltre 515.000 recensioni di hotel di lusso in Europa, raccolte dal sito Booking.com, dove sono pubblicamente accessibili. Ogni riga del dataset corrisponde ad una recensione e presenta 17 campi che descrivono sia le caratteristiche dell'hotel, sia l'esperienza del cliente.

- **Dimensione File:** Circa 238 MB
- **Numero di Righe:** 515.738

2.1 Campi del Dataset

- **Hotel_Address:** Indirizzo dell'hotel.
- **Additional_Number_of_Scorings:** Numero di valutazioni aggiuntive (clienti che hanno lasciato solo una valutazione numerica dell'hotel, senza recensione).
- **Review_Date:** Data in cui è stata rilasciata la recensione.
- **Average_Score:** Punteggio medio storico dell'hotel (calcolato su tutte le recensioni ricevute dall'hotel nell'ultimo anno).
- **Hotel_Name:** Nome della struttura.
- **Reviewer_Nationality:** Nazionalità dell'utente che ha lasciato la recensione.
- **Negative_Review:** Testo del commento negativo ("No Negative" se assente).
- **Review_Total_Negative_Word_Counts:** Conteggio parole commento negativo.
- **Total_Number_of_Reviews:** Totale recensioni ricevute dall'hotel.

- **Positive_Review:** Testo del commento positivo ("No Positive" se assente).
- **Review_Total_Positive_Word_Counts:** Conteggio parole commento positivo.
- **Total_Number_of_Reviews_Reviewer_Has_Given:** Numero di recensioni rilasciate dell'utente in passato.
- **Reviewer_Score:** Voto assegnato dal recensore all'hotel.
- **Tags:** Lista di stringhe che descrivono il soggiorno (es. "Leisure trip", "Couple", "Stayed 2 nights").
- **days_since_review:** Giorni trascorsi fra la pubblicazione e lo scraping della recensione.
- **lat:** Latitudine dell'hotel.
- **lng:** Longitudine dell'hotel.

3 Descrizione delle Query Implementate

3.1 Trend Recensioni (Time Series)

Obiettivo: Analizzare il **trend temporale** dei punteggi degli hotel (utilizzando la Regressione Lineare) per identificare quali alberghi stanno migliorando o peggiorando nel tempo.

The screenshot shows a user interface for 'Hotel Reviews Analytics con Spark'. On the left, there's a sidebar titled 'Opzioni Query' with various analysis options listed as radio buttons. The selected option is 'Trend Recensioni (Time Series)'. The main area is titled 'Hotel Reviews Analytics con Spark' and contains the following information:

- Query selezionata: Trend Recensioni (Time Series)**
- Analizza il trend temporale dei punteggi di ogni hotel, utilizzando la Regressione Lineare.
- L'obiettivo è capire se un hotel sta migliorando o peggiorando nel tempo.
- Viene identificato se la **reputazione** dell'hotel è:
 - In crescita: quando la pendenza della retta di regressione lineare è positiva.
 - In decrescita: quando la pendenza della retta di regressione lineare è negativa.
 - Stabile: quando la pendenza della retta di regressione lineare è zero.
- Legenda Campi:**
 - Trend_Slope : Pendenza della retta di regressione lineare.
 - Review_Count : Numero totale di recensioni dell'hotel.
 - Average_Score_Calculated : Punteggio medio calcolato sulle recensioni presenti nel dataset.
 - Average_Score : Punteggio medio calcolato su tutte le recensioni ricevute dall'hotel nell'ultimo anno (anche quelle che non sono presenti nel dataset).
 - First_Review_date : Data della prima recensione dell'hotel.
 - Last_Review_date : Data della ultima recensione dell'hotel.
- Nota:** Il calcolo del trend viene effettuato tenendo conto solo delle recensioni presenti nel dataset che hanno una data valida. Inoltre, vengono esclusi gli hotel con meno di 30 recensioni valide.
- Minimo numero di recensioni per albergo:
- Calcola Trend per tutti gli Hotel

Figura 2: Query Trend Recensioni (Time Series)

Logica Backend:

- Le recensioni vengono **raggruppate per hotel** e ordinate cronologicamente.
- Per ogni gruppo (stesso hotel): da ogni recensione si estraggono i valori di **Reviewer_Score** e **Review_Date** (convertita in ordinale), quindi viene applicata una **regressione lineare (score vs tempo)** per calcolare la pendenza (**slope**) del **trend**. Inoltre, si effettua il calcolo di **altri valori aggregati**: punteggio medio, numero di recensioni, data della prima recensione, data dell'ultima recensione.
- Viene restituito un dataframe contenente i risultati ottenuti per ogni hotel.

Tecnologie: Viene definita una Pandas UDF (User Defined Function) per l'esecuzione della regressione lineare con **scikit-learn**. La UDF viene eseguita con la funzione `applyInPandas` affinché questa operazione sia parallelizzabile su ogni gruppo di hotel distribuito nei nodi Spark.

Risultati: Viene visualizzata la lista dei **Top 10 Hotel in Crescita** e dei **Top 10 Hotel in Calo**, ordinati per trend slope (Figura 3), dove trend positivo indica miglioramento, mentre trend negativo indica peggioramento. Inoltre, viene visualizzato il grafico **Distribuzione Trend vs Punteggio Medio** (Figura 4) che consente di individuare visivamente gli alberghi migliori o peggiori e leggerne le caratteristiche.

Casi d'uso: Identificare "stelle nascenti" o **hotel decadenti** nonostante un alto punteggio medio storico.

Top 10 Hotel in Crescita						
Hotel_Name	Trend_Slope	Review_Count	Average_Score_Calculated	Average_Score	First_Review_Date	Last_Review_Date
1076 The Curtain	0.0064	39	8.8833	9.1	2017-05-25	2017-08-03
931 Chasse Hotel	0.0059	139	9.0144	8.9	2017-09-27	2017-08-02
125 Hotel Park Lane Paris	0.0041	154	8.6338	8.7	2016-05-23	2017-08-03
1096 Villa Lut ce Port Royal	0.004	47	6.3851	7	2015-08-15	2017-05-02
853 NYX Milan	0.0035	180	8.5956	8.8	2017-02-25	2017-08-03
552 Hotel Capitol Milano	0.0031	66	8.1242	8.3	2015-04-22	2017-07-05
1298 Lansbury Heritage Hotel	0.0031	49	9.5175	9.4	2017-04-25	2017-08-02
1126 Best Western Le 18 Paris	0.0031	86	7.4291	7.6	2016-03-22	2017-07-20
265 Bob Hotel Elegancia	0.003	49	8.9388	9	2017-03-12	2017-08-02
90 Hilton London Euston	0.0025	470	7.1209	7.4	2015-08-04	2017-08-02

Top 10 Hotel in Calo						
Hotel_Name	Trend_Slope	Review_Count	Average_Score_Calculated	Average_Score	First_Review_Date	Last_Review_Date
632 Okko Hotels Paris Porte De Versailles	-0.0082	43	9.0837	9.2	2017-06-09	2017-07-31
1019 Le Tsuba Hotel	-0.0067	57	9.0807	9.3	2017-03-25	2017-08-02
380 Marlin Waterloo	-0.0062	84	8.3548	8.6	2017-05-29	2017-08-03
917 Arthotel ANA Westbahn	-0.0049	67	8.4418	8.3	2017-03-02	2017-08-03
1025 Maison Albar Hotel Paris C line	-0.0047	62	9.0065	8.9	2016-12-25	2017-08-03
1297 La Villa Haussmann	-0.0046	41	9.1561	9.2	2017-01-10	2017-08-02
1314 Majestic Hotel Spa	-0.0045	38	8.4842	8.7	2015-08-18	2017-07-29
904 Villa Eugenie	-0.0044	62	5.9645	6.8	2015-08-05	2017-08-02
830 London Suites	-0.0044	114	7.3211	7.4	2016-07-03	2017-08-02
183 Park Plaza London Park Royal	-0.004	197	8.901	8.9	2017-03-10	2017-08-03

Figura 3: Top 10 Hotel in Crescita/Calo

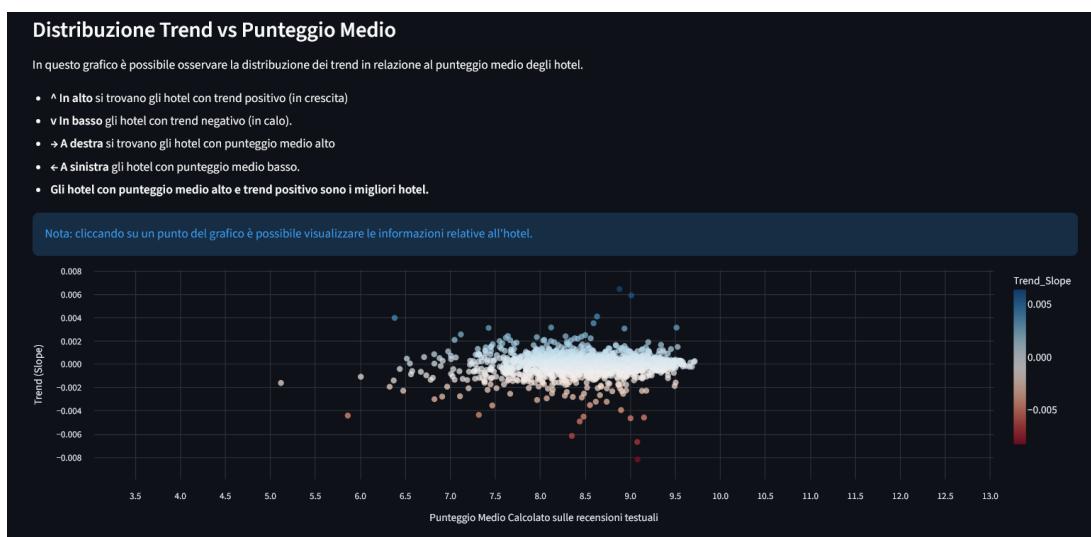


Figura 4: Distribuzione Trend vs Punteggio Medio

3.2 Analisi Influenza Tag

Obiettivo: Determinare quali fattori (es. "Single Room", "No Window") impattano positivamente o negativamente sul punteggio che i recensori assegnano agli hotel.

The screenshot shows a user interface for 'Hotel Reviews Analytics con Spark'. On the left, a sidebar titled 'Opzioni Query' lists various analysis options, with 'Analisi Influenza Tag' selected. The main area is titled 'Query selezionata: Analisi Influenza Tag' and contains detailed documentation about the analysis. It explains that the query analyzes the impact of tags found in reviews (e.g., 'double bedroom', 'no windows') to determine which hotel characteristics positively or negatively influence reviews. It includes a map operation (Explode) to list tags per review, a reduce operation (Aggregate) to calculate average score, frequency, and standard deviation, and an analysis of each tag. The analysis includes metrics like Average_Score, Count, Impact, StdDev_Score, Reliability_Index, and Weighted_Impact. A slider at the bottom indicates a minimum of 50 occurrences per tag. At the bottom right is a button labeled 'Analizza Influenza Tag'.

Figura 5: Query Analisi Influenza Tag

Logica Backend:

- Le recensioni vengono "esplose": si prende in input la stringa dei tag di ogni recensione, la stringa viene suddivisa in singoli tag, ciascuno dei quali viene poi "ripulito" da eventuali spazi vuoti o lettere maiuscole, e infine si produce in output una riga per ogni singolo tag letto in input (gli altri campi della riga vengono duplicati dalla recensione originale da cui è stato estratto il tag).
- Le righe risultanti vengono raggruppate per tag, eseguendo delle operazioni di **aggregazione** sugli hotel associati ad ogni tag: conteggio del numero di hotel, calcolo del punteggio medio degli hotel e calcolo della **deviazione standard** (ad esempio, se la deviazione standard è alta, significa che i voti sono molto dispersi, quindi la valutazione del peso di quel tag sarà meno affidabile).
- Viene calcolata la **media globale** sui punteggi medi di tutti i tag, per poter avere un indice di confronto sulla base del quale valutare se un tag ha un **impatto** positivo o negativo rispetto agli altri (ad esempio, se un tag ha una media di 9.0 e la media globale è 8.5, allora quel tag ha un "impatto positivo" (+0.5)).
- Per ogni tag, vengono calcolati:

$$\text{Impact} = \text{Average_Score} - \text{Global_Average}$$

$$\text{Reliability_Index} = (1 / (\text{StdDev} + 0.1)) * \log(\text{Count})$$

$$\text{Weighted_Impact} = \text{Impact} * \text{Reliability_Index}$$
 Il Reliability_Index è un indice euristico che valuta quanto è attendibile l'impatto di un tag, premiando i tag con una maggiore stabilità dei voti (deviazione standard bassa) e con un'alta frequenza (il logaritmo serve per mitigare l'impatto dei tag estremamente frequenti).
- Viene restituito un dataframe contenente i risultati ottenuti per ogni tag.

Risultati: Vengono visualizzate le classifiche dei **tag con il maggior impatto positivo e negativo** (Figura 6), ordinati per **Weighted_Impact** decrescente/crescente. Inoltre, viene visualizzato il grafico **Affidabilità vs Impatto** (Figura 7), che consente di individuare i fattori che influenzano maggiormente (in positivo o in negativo) la valutazione degli hotel e valutare a colpo d'occhio il grado di attendibilità di ciascuno di essi.

Casi d'uso: Identificare le **caratteristiche più apprezzate o criticate** dai clienti degli hotel.

Media Globale Voti (calcolata su tutte le recensioni): 8.40						
👉 Top 10 Tag Positivi (per Weighted Impact)						
Tag più affidabili che alzano il voto.						
Single_Tag	Average_Score	Count	Impact	Reliability_Index	Weighted_Impact	
0 Camper Room	9.73	225	1.33	9.04	12.04	
1 Kings Junior Suite	9.65	55	1.26	6.95	8.76	
2 Luxury Double or Twin Room	9.68	68	1.28	6.78	8.67	
3 Double or Twin Room Allergy Free	9.69	50	1.30	5.97	7.74	
4 Double Room XL	9.67	58	1.28	5.49	7.00	
5 Deluxe Double Room 12 Adults	9.53	305	1.13	5.73	6.48	
6 Small Double Room Annex building	9.56	72	1.17	5.14	6.01	
7 Double Room Annex	9.43	187	1.03	5.68	5.88	
8 Delightful Queen Room	9.56	64	1.17	5.03	5.87	
9 City King Room	9.30	739	0.91	6.47	5.86	
💡 Top 10 Tag Negativi (per Weighted Impact)						
Tag più affidabili che abbassano il voto.						
Single_Tag	Average_Score	Count	Impact	Reliability_Index	Weighted_Impact	
660 Standard Double Room without Window	7.03	2424	-1.36	3.63	-4.96	
659 Cabin Single Room	6.63	195	-1.76	2.64	-4.65	
658 Standard Double Room No Window	6.98	470	-1.41	3.14	-4.44	
657 Eiffel Tower View King Room	6.65	109	-1.75	2.18	-3.82	

Figura 6: Top 10 Tag Positivi/Negativi



Figura 7: Grafico Affidabilità vs Impatto

3.3 Analisi Bias Nazionalità

Obiettivo: Individuare, se esistono, le nazionalità che tendono a dare voti più alti o bassi rispetto alla media.



Figura 8: Query Analisi Bias Nazionalità

Logica Backend:

- Raggruppamento delle recensioni per **Reviewer_Nationality**.
- Calcolo di valori aggregati per ogni nazionalità: numero di recensioni, media dei punteggi assegnati nelle recensioni, media del numero di parole positive scritte nelle recensioni, media del numero di parole negative scritte nelle recensioni.
- Calcolo della **media globale** di tutti i punteggi assegnati in tutte le recensioni (da utilizzare per confronto).
- Calcolo dello **Score Deviation** di ogni nazionalità, cioè la differenza fra la media dei punteggi assegnati da recensori di quella nazionalità e la media globale. Questa metrica indica se mediamente i recensori di una certa nazionalità sono più **critici (deviazione negativa)** o **generosi (deviazione positiva)** nell'assegnare le valutazioni degli hotel.
- Calcolo del **Sentiment_Ratio** di ogni nazionalità, cioè il rapporto fra numero di parole positive e negative utilizzate nelle recensioni. Questa metrica, quando considerata in relazione con il punteggio medio assegnato dai recensori di una certa nazionalità, indica la **coerenza** di questi recensori: chi dà più spesso valutazioni numeriche positive dovrebbe avere un **Sentiment_Ratio** positivo (cioè dovrebbe utilizzare mediamente più parole positive che negative), mentre chi è più critico e dà più spesso valutazioni numeriche negative dovrebbe avere un **Sentiment_Ratio** negativo.
- Restituzione del dataset aggregato per **Reviewer_Nationality**, con le metriche calcolate.

Risultati: Vengono visualizzate le classifiche delle **nazionalità più critiche e più generose** (Figura 9), ordinate per **Score Deviation** crescente/decrescente. Inoltre, viene visualizzato il grafico **Correlazione Voto vs Positività Testo** (Figura 10), che consente di valutare visivamente la coerenza dei recensori per ogni nazionalità.

Casi d'uso: Profilazione per nazionalità e identificazione di bias culturali che peggiorano o migliorano l'esperienza dei clienti.

Media Globale Voti
8.40

I Più Critici (Voti Bassi)

	Reviewer_Nationality	Average_Score	Count	Score_Deviation	Sentiment_Ratio	Total_Words_Avg
140	Mongolia	7.25	39	-1.14	0.42	20.72
139	Syria	7.52	33	-0.87	0.24	36.85
138	Libya	7.60	72	-0.80	0.43	23.06
137	Seychelles	7.60	21	-0.80	0.43	30.14
136	Bangladesh	7.61	151	-0.79	0.46	26.85
135	Iran	7.73	1086	-0.67	0.47	26.62
134	Algeria	7.78	100	-0.62	0.44	21.55
133	Tanzania	7.81	58	-0.59	0.42	26.14
132	Jordan	7.81	757	-0.59	0.43	27.30
131	Pakistan	7.81	916	-0.59	0.49	27.81

I Più Generosi (Voti Alti)

	Reviewer_Nationality	Average_Score	Count	Score_Deviation	Sentiment_Ratio	Total_Words_Avg
0	Kyrgyzstan	9.00	21	0.60	0.53	37.05
1	Liechtenstein	8.89	20	0.49	0.59	31.60
2	Puerto Rico	8.80	180	0.41	0.62	29.08
3	Panama	8.80	122	0.41	0.51	25.35

Figura 9: Classifica nazionalità più critiche e più generose



Figura 10: Grafico Correlazione Voto vs Positività Testo

3.4 Analisi Competitività Locale

Obiettivo: Confrontare le performance di un hotel rispetto ai suoi concorrenti geograficamente più vicini.

The screenshot shows a user interface for 'Hotel Reviews Analytics con Spark'. On the left, a sidebar titled 'Opzioni Query' lists several analysis options, with 'Analisi Competitività Locale' being the selected one. The main panel is titled 'Hotel Reviews Analytics con Spark' and displays the 'Analisi Competitività Locale' query. It provides instructions to compare each hotel with its neighbors within a N km radius, identifying 'Gemme Locali (Outperformers)' and 'Hotel sotto la media (Underperformers)'. Below this, a section titled 'Logica di funzionamento:' outlines the process: 1. Calculate the distance between each hotel and its competitors using the Haversine formula; 2. Exclude competitors outside the specified search radius; 3. Analyze the following statistics for each hotel: Average_Score (average review score), Neighborhood_Avg_Score (average score of competitors in the neighborhood), Score_Delta (difference between hotel score and neighborhood average), and Competitor_Count (number of competitors in the neighborhood). A slider for the 'Raggio di ricerca (km)' is set to 2.00, and a dropdown for 'Minimo numero di competitor nella zona' is set to 5. At the bottom is a button labeled 'Analizza Competitività'.

Figura 11: Query Analisi Competitività Locale

Logica Backend:

- Esegue un **self-join** del dataset per calcolare tutte le possibili coppie di hotel distinti: Hotel_A e Hotel_B.
- Calcola la **distanza geografica fra ogni coppia di hotel** (utilizzando la Formula di Haversine).
- Filtra le coppie di hotel, mantenendo solo quelle che hanno una distanza inferiore a N chilometri (N è un parametro scelto dall'utente).
- Raggruppa per Hotel_A, ottenendo per ogni hotel il suo vicinato. Poi aggrega i campi degli hotel appartenenti al vicinato, calcolando **punteggio medio del vicinato** e **numero di concorrenti**. Infine, calcola **Score_Delta** = differenza fra il punteggio di Hotel_A e la media del vicinato.
- Classifica come **Outperformer** gli hotel con **Score_Delta > 0** e come **Underperformer** quelli con **Score_Delta < 0**. Infine, restituisce il dataset con i valori aggregati appena calcolati.

Risultati: Vengono visualizzate le classifiche delle **Gemme Locali (i migliori Outperformer)** e dei **peggiori Underperformer** (Figura 12), ordinate per **Score_Delta** decrescente/crescente. Inoltre, viene visualizzato il grafico **Performance Relativa** (Figura 13), che consente di individuare visivamente gli hotel che appartengono all'una o all'altra categoria, confrontando il voto dell'hotel con il voto medio del suo vicinato.

Casi d'uso: Analisi della competitività fra attività geograficamente vicine.

Top 10 Gemme Locali (Meglio dei competitor vicini)					
	Hotel_Name	Average_Score	Neighborhood_Avg_Score	Score_Delta	Competitor_Count
0	Milestone Hotel Kensington	9.50	8.23	1.27	100
1	Ritz Paris	9.80	8.59	1.21	230
2	Nu Hotel	8.90	7.82	1.08	5
3	Hotel The Peninsula Paris	9.50	8.44	1.06	129
4	Waldorf Astoria Amsterdam	9.50	8.48	1.02	65
5	Haymarket Hotel	9.60	8.59	1.01	134
6	Pillows Anna van den Vondel Amsterdam	9.40	8.39	1.01	47
7	Hotel Eiffel Blomet	9.40	8.39	1.01	46
8	Charlotte Street Hotel	9.50	8.49	1.01	136
9	Hotel de La Tamise Esprit de France	9.60	8.61	0.99	228

⚠️ Top 10 Sotto la Media (Peggio dei competitor vicini)					
	Hotel_Name	Average_Score	Neighborhood_Avg_Score	Score_Delta	Competitor_Count
1376	Hotel Liberty	5.20	8.42	-3.22	41
1375	Hotel Cavendish	6.40	8.53	-2.13	120
1374	The Tophams Hotel	6.60	8.71	-2.11	88
1373	Savoy Hotel Amsterdam	6.40	8.35	-1.95	41
1372	Britannia International Hotel Canary Wharf	7.10	8.96	-1.86	8
1371	Bloomsbury Palace Hotel	6.80	8.53	-1.73	119

Figura 12: Classifica migliori Outperformer e peggiori Underperformer

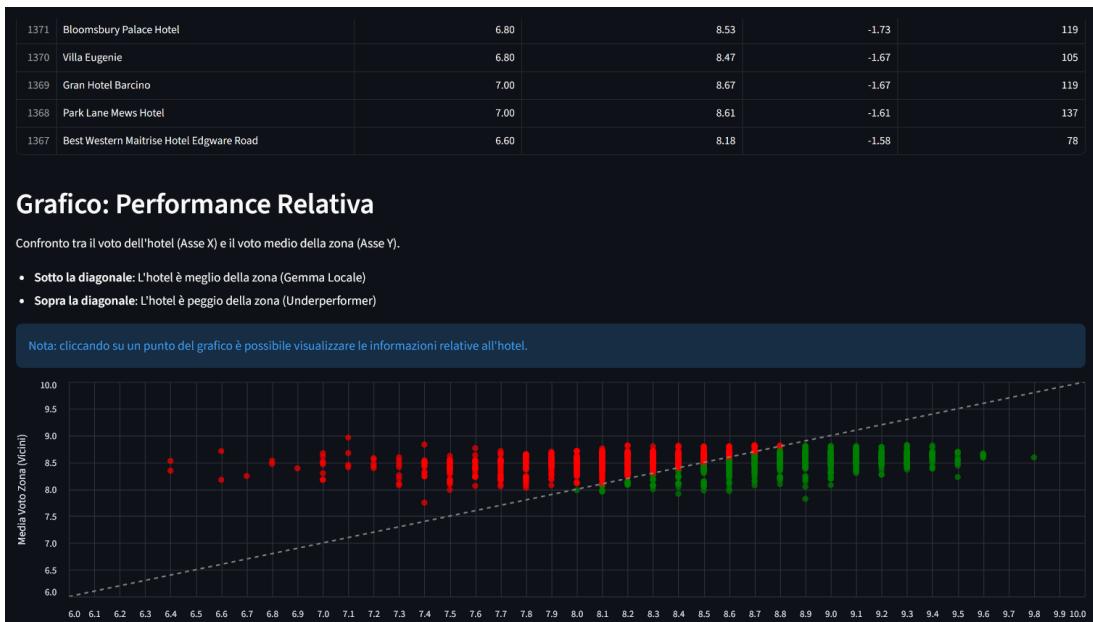


Figura 13: Grafico Performance Relativa

3.5 Segmentazione Hotel (K-Means Clustering)

Obiettivo: Raggruppare gli hotel in cluster omogenei (utilizzando K-Means Clustering), sulla base delle seguenti feature: Punteggio Medio, Popolarità (numero recensioni), Verbosità delle recensioni, Posizione geografica, Bias di nazionalità. L'utente seleziona fra queste le caratteristiche sulla base delle quali saranno raggruppati gli hotel. Inoltre, può scegliere il numero di gruppi in cui effettuare la suddivisione.



Figura 14: Query Segmentazione Hotel (K-Means Clustering)

Logica Backend:

- Raggruppamento per hotel e aggregazione per il calcolo delle feature.
- Creazione di vettore delle feature con VectorAssembler e normalizzazione con StandardScaler.
- Clustering degli hotel con algoritmo K-Means.

Tecnologie: Da Spark MLlib: VectorAssembler, StandardScaler, KMeans, Pipeline).

Risultati: Assegnazione di ogni hotel a un cluster (es. "Hotel Popolari di Lusso", "Hotel Economici di Nicchia").

- Analisi delle caratteristiche di ogni cluster (Figura 15).
- Mappa interattiva della distribuzione geografica dei cluster (Figura 16).
- Grafico interattivo per l'esplorazione delle performance dei cluster, con possibilità di confrontare: Punteggio medio, Numero di recensioni, Numero medio di parole positive nelle recensioni, Numero medio di parole negative nelle recensioni (Figura 17).
- Grafico della distribuzione delle nazionalità dei cluster (Figura 18).

Casi d'uso: Segmentazione di marketing, raccomandazioni di hotel simili.

	Cluster Name	Count	Avg_Score	Total_Reviews	Avg_Pos_Words	Avg_Neg_Words
0	Cluster 0	207	8.50	1425	19.5	18.3
1	Cluster 1	844	8.50	800	18.8	17.2
2	Cluster 2	297	8.43	1418	18.4	17.5
3	Cluster 3	127	8.28	4124	17.2	19.6

Figura 15: Analisi delle caratteristiche di ogni cluster

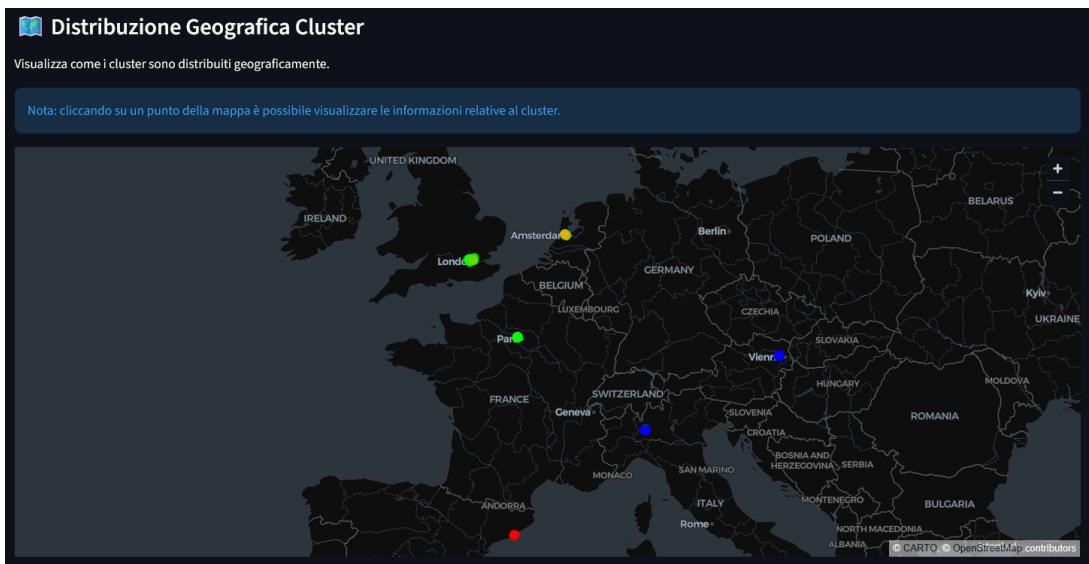


Figura 16: Mappa interattiva della distribuzione geografica dei cluster

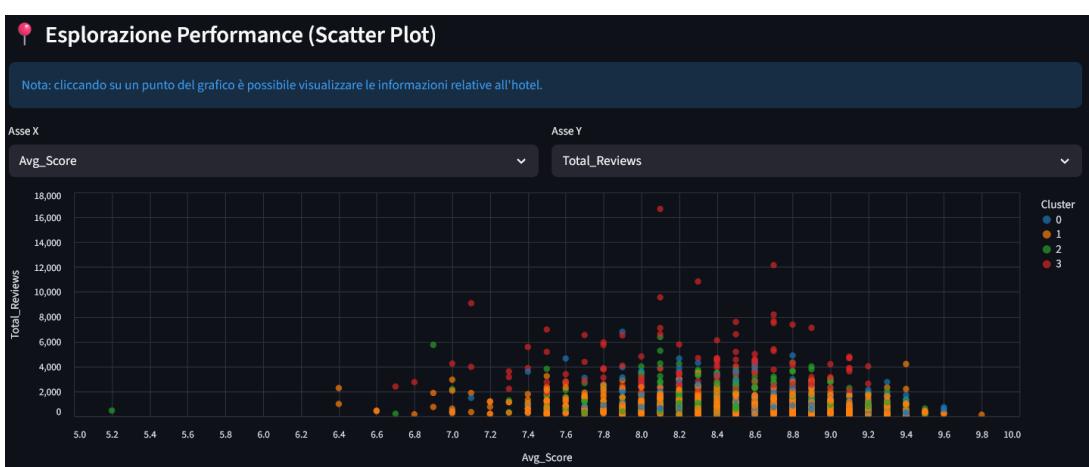


Figura 17: Grafico interattivo per l'esplorazione delle performance dei cluster

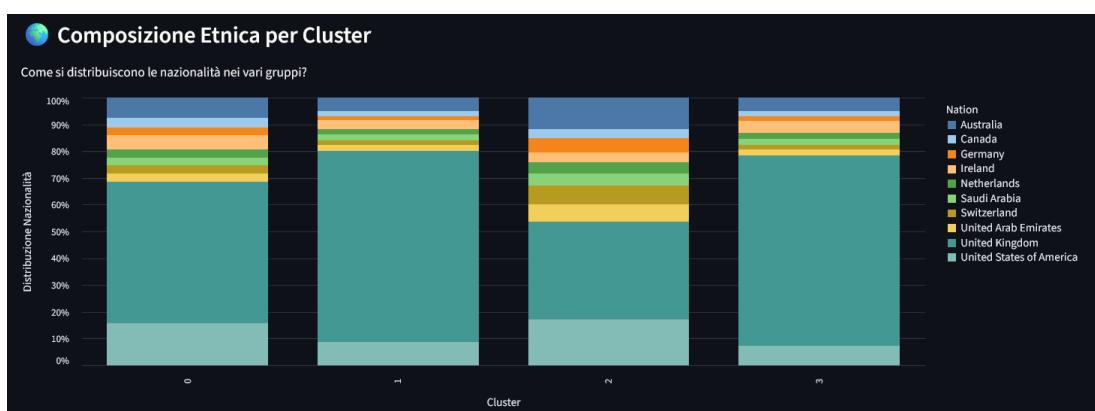


Figura 18: Grafico della distribuzione delle nazionalità dei cluster

3.6 Migliori Hotel per Nazione

Obiettivo: Identificare le eccellenze alberghiere suddivise per paese.

The screenshot shows a user interface for hotel review analytics. On the left, there is a sidebar titled 'Opzioni Query' (Query Options) with various analytical tasks listed as radio buttons. The 'Migliori Hotel per Nazione' option is selected and highlighted with a red dot. The main area is titled 'Hotel Reviews Analytics con Spark' and contains a section titled 'Query selezionata: Migliori Hotel per Nazione'. It includes a descriptive text about the query's purpose, a dropdown for selecting the number of top hotels to display (set to 3), and a button labeled 'Analizza per Nazione'.

Figura 19: Query Migliori Hotel per Nazione

Logica Backend:

- Deduplicazione degli hotel nelle recensioni.
- Estrazione della nazione dall’indirizzo dell’hotel.
- Raggruppamento delle strutture per nazione e ordinamento in base al punteggio medio e al numero di recensioni (in caso di parità).

Risultati: Viene visualizzata la lista dei top N hotel per ogni nazione presente nel dataset (le nazioni sono presentate in ordine alfabetico) e la distribuzione dei punteggi dei migliori hotel in assoluto (Figura 20). Inoltre, viene visualizzata la mappa geografica che mostra dove si trovano gli hotel (Figura 21).

Casi d’uso: Utenti che cercano i migliori hotel in una specifica destinazione turistica.



Figura 20: Top N Hotel per Nazione e Distribuzione dei Punteggi degli Hotel

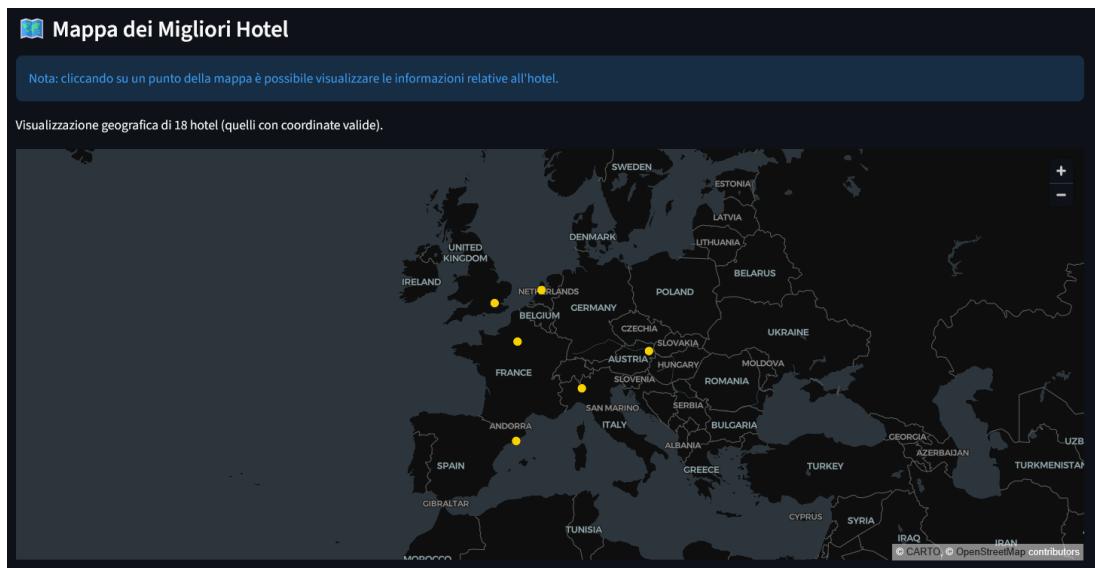


Figura 21: Mappa dei Migliori Hotel

3.7 Locals vs Tourists - Preferenze e distribuzione clienti

Obiettivo: Analizzare la differenza di percezione tra chi visita il proprio paese (Local) e chi viene dall'estero (Tourist).

The screenshot shows a user interface for 'Hotel Reviews Analytics con Spark'. On the left, a sidebar titled 'Opzioni Query' lists various analysis options like 'Trend Recensioni (Time Series)', 'Analisi Influenza Tag', etc., with 'Locals vs Tourists - Preferenze e distribuzione clienti' selected. The main area is titled 'Hotel Reviews Analytics con Spark' and displays the results for the selected query: 'Locals vs Tourists - Preferenze e distribuzione clienti'. It includes sections for 'Locals' Favorites vs Tourist Traps' (describing how perception changes based on location), 'Indicatori' (listing metrics like Local_Avg_Score and Tourist_Avg_Score), and 'Distribuzione Nazionalità' (visualizing nationality distribution with a slider for minimum reviews per group set at 20). A button at the bottom says 'Analizza Preferenze'.

Figura 22: Query Locals vs Tourists - Preferenze e distribuzione clienti

Logica Backend:

- Estrazione della nazione dall'indirizzo dell'hotel e della nazionalità del recensore, poi classificazione fra Local (stessa nazione) e Tourist.
- Raggruppamento per hotel e nazione, poi pivot su tipologia di recensore (Local o Tourist) e infine calcolo di valori aggregati: `Local_Avg_Score`, `Tourist_Avg_Score` e differenza fra i due valori (`Preference_Delta`).
- Calcolo della percentuale di recensioni proveniente da ogni gruppo nazionale per ogni hotel:
 - Aggregazione per hotel e calcolo numero totale di recensioni.
 - Aggregazione per hotel e nazionalità recensore per calcolo numero di recensioni da recensori con stessa nazionalità.
 - Calcolo percentuale di recensioni di ogni nazionalità rispetto al totale delle recensioni, per ogni hotel.

Risultati:

- Liste degli hotel preferiti dai locali (`Preference_Delta` positivo) e degli hotel preferiti dai turisti (`Preference_Delta` negativo), ordinati per `Preference_Delta`, in modo da visualizzare per primi gli hotel che hanno le maggiori discrepanze di voto (Figura 23).
- Grafico Discrepanza Voti per individuare visivamente la distribuzione degli hotel in relazione alla tipologia di clientela che li apprezza di più o di meno (Figura 24).
- Grafico Distribuzione Nazionalità per visualizzare la composizione percentuale delle nazionalità dei visitatori degli Hotel (Figura 25).

Casi d'uso: Identificazione di "Trappole per turisti" o "Preferiti dai locali" (hotel che potrebbero offrire un'esperienza più autentica).

Discrepanza Media (Local - Tourist) +0.19

Hotel preferiti dai Locali (Rispetto ai Turisti)

Hotel dove il voto dei locali supera di più quello dei turisti.

Hotel_Name	Hotel_Nation	Local_Avg_Score	Tourist_Avg_Score	Preference_Delta	Top_Nationalities
0 Simply Rooms Suites	United Kingdom	7.91	6.67	1.24	Spain (2%), United Kingdom (78%)
1 London Suites	United Kingdom	7.62	6.74	0.89	Italy (2%), France (2%), Austria (3%), United Kingdom (65%), Australia (4%)
2 Crowne Plaza London Docklands	United Kingdom	8.88	8.04	0.85	United Kingdom (89%), Ireland (2%)
3 Sheraton Grand London Park Lane	United Kingdom	8.44	7.61	0.83	Turkey (2%), United Arab Emirates (6%), Kuwait (5%), Saudi Arabia (7%), Australia (5%), United Kingdom (80%)
4 DoubleTree by Hilton London West End	United Kingdom	8.43	7.63	0.80	United Arab Emirates (2%), United States of America (2%), South Africa (2%), Kuwait (4%), Saudi Arabia (4%), Kuwait (5%), Israel (4%), Ireland (2%), Australia (2%), United States of America (2%)
5 The Westbury A Luxury Collection Hotel Mayfair London	United Kingdom	8.49	7.72	0.77	United Arab Emirates (2%), United States of America (2%), South Africa (2%), Kuwait (4%), Saudi Arabia (4%), Kuwait (5%), Israel (4%), United Arab Emirates (5%), United States of America (6%), United Kingdom (80%)
6 DoubleTree by Hilton Hotel London Marble Arch	United Kingdom	8.43	7.67	0.76	Saudi Arabia (4%), Kuwait (5%), Israel (4%), Ireland (2%), Australia (2%), United States of America (2%)
7 The Dorchester Dorchester Collection	United Kingdom	9.52	8.77	0.75	Saudi Arabia (4%), Kuwait (4%), United Arab Emirates (5%), United States of America (6%), United Kingdom (51%), India (2%), Israel (2%)
8 Holiday Inn London Oxford Circus	United Kingdom	7.70	6.96	0.75	Kuwait (3%), United Arab Emirates (2%), United Kingdom (57%), India (2%), Ireland (2%), Israel (2%)
9 Novotel London Paddington	United Kingdom	8.80	8.06	0.73	United States of America (5%), Ireland (2%), United Kingdom (51%), Saudi Arabia (5%), New Zealand (2%)

Hotel_Name	Hotel_Nation	Local_Avg_Score	Tourist_Avg_Score	Preference_Delta	Top_Nationalities
458 Austria Trend Hotel Bosai Wien	Austria	6.76	8.18	-1.43	Poland (4%), Croatia (2%), United Kingdom (6%), Bulgaria (2%), Israel (2%), Belgium (2%), Czech Republic (2%), United Kingdom (11%), Italy (2%), Kuwait (7%), Qatar (3%)
457 Rosa Grand Milano Starhotels Collezione	Italy	7.39	8.46	-1.07	United Arab Emirates (8%), Israel (2%), United Kingdom (11%), Italy (2%), Kuwait (7%), Qatar (3%)
456 Hampshire Hotel The Manor Amsterdam	Netherlands	7.49	8.54	-1.05	Ireland (3%), Australia (3%), Netherlands (7%), United States of America (8%), United Kingdom (4%)
455 Arthotel ANA Boutique Six	Austria	7.11	8.10	-0.99	Russia (2%), Croatia (2%), Hungary (3%), Israel (2%), Italy (3%), Poland (2%), United Kingdom (11%), United States of America (4%), Germany (4%), Netherlands (10%), Israel (2%), United Kingdom (66%), Israel (18%), United States of America (3%)
454 Savoy Hotel Amsterdam	Netherlands	5.33	6.09	-0.76	France (2%), United States of America (4%), Germany (4%), Netherlands (10%), Israel (2%), United Kingdom (66%), Israel (18%), United States of America (3%)
453 The Pillar Hotel	United Kingdom	8.15	8.88	-0.73	United Kingdom (66%), Israel (18%), United States of America (3%)
452 Eurostars Grand Marina Hotel GL	Spain	7.74	8.47	-0.73	Saudi Arabia (9%), United Kingdom (33%), Kuwait (4%), Australia (2%), Ireland (2%), Spain (2%), United Kingdom (48%), Spain (2%), United States of America (5%), Netherlands (2%)
451 Catalonia Atenas	Spain	7.43	8.09	-0.66	Ireland (6%), United Kingdom (48%), Spain (2%), United States of America (5%), Netherlands (2%)
450 Courtyard by Marriott Amsterdam Arena Atlas	Netherlands	7.95	8.57	-0.62	United Arab Emirates (2%), United States of America (5%), Turkey (2%), Germany (6%), Netherlands (2%)
449 Ramada Apollo Amsterdam Centre	Netherlands	7.71	8.31	-0.60	Netherlands (2%), United States of America (5%), Australia (2%), United Kingdom (49%), Ireland (2%)

Figura 23: Liste degli hotel preferiti dai locali e degli hotel preferiti dai turisti

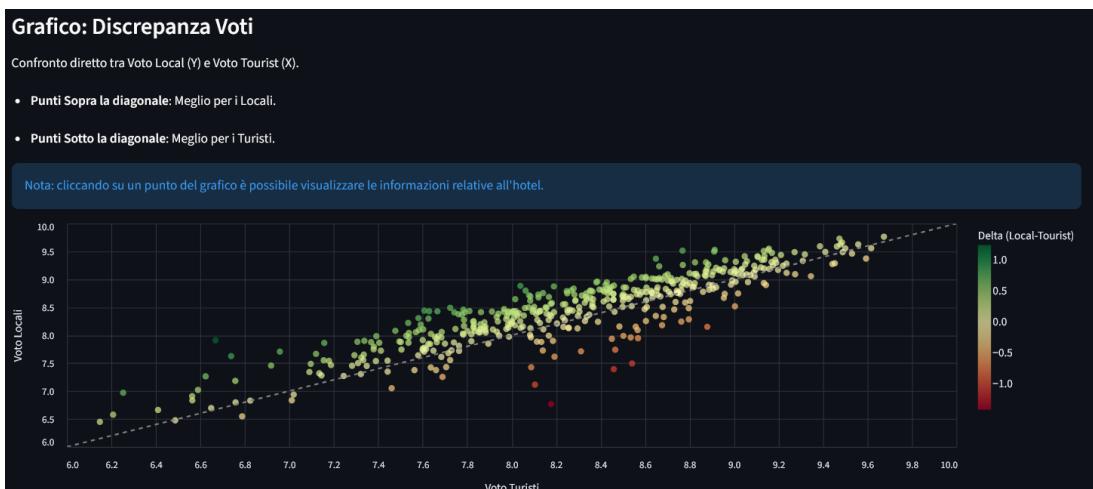


Figura 24: Grafico Discrepanza Voti

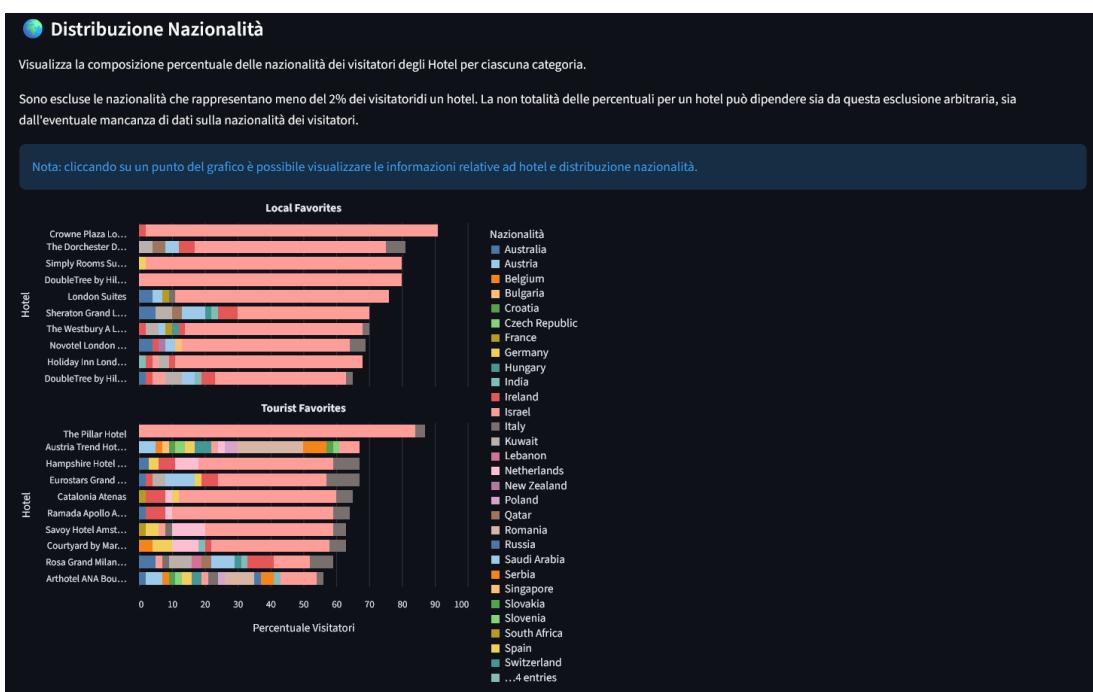


Figura 25: Grafico Distribuzione Nazionalità

3.8 Analisi Stagionale & Target

Obiettivo: Analizzare come varia il gradimento in base alla stagione e al tipo di viaggio (Leisure/Business/Solo/Family/Group/Couple).

The screenshot shows a user interface for 'Hotel Reviews Analytics con Spark'. On the left, a sidebar titled 'Opzioni Query' lists various analysis options: Trend Recensioni (Time Series), Analisi Influenza Tag, Analisi Bias Nazionalità, Analisi Competitività Locale, Segmentazione Hotel (K-Means), Migliori Hotel per Nazione, Locals vs Tourists - Preferenze e distribuzione clienti, Analisi Stagionale & Target (which is selected), Analisi Durata Soggiorno, and Analisi Esperienza Recensore. The main area is titled 'Hotel Reviews Analytics con Spark' and displays the selected query: 'Analisi Stagionale & Target'. Below this, there's a section titled 'Analisi Stagionale e Profilazione Viaggiatore' with a subtitle 'Scopri quando andare e con chi. Questa query analizza come cambiano le performance degli hotel in base alla Stagione e al Tipo di Viaggiatore.' It includes two sets of checkboxes: 'Selezione Stagioni:' (Winter, Spring, Summer, Autumn) and 'Selezione Tipo Viaggiatore:' (Family, Couple, Business, Solo, Group, Leisure). A slider bar indicates a minimum of 10 reviews per hotel. At the bottom is a button labeled 'Analizza Stagionalità'.

Figura 26: Query Analisi Stagionale & Target

Logica Backend:

- Estrazione **mese** dalla data della recensione.
- Estrazione **tipologia di viaggiatore** analizzando i tag della recensione: poichè una recensione potrebbe appartenere a più tipi contemporaneamente (es. Solo e Business, Group e Leisure), si applica la seguente logica:
 - si estrae tutta la lista dei tag e si filtrano solo quelli utili
 - per ogni tag si genera una nuova riga in cui il campo **Traveler_Type** assume il valore di quel tag (i valori degli altri campi vengono duplicati dalla riga originale).
- **Aggregazione** per Hotel, Stagione e Tipologia di Viaggiatore, calcolando punteggio medio e numero di recensioni.

Risultati:

- Lista degli hotel migliori in base alle stagioni e alle tipologie di viaggio selezionate, ordinati per punteggio medio (Figura 27).
- Heatmap Stagionale Hotel per visualizzare dettagliatamente le performance di un hotel in ogni possibile combinazione di stagione e tipologia di viaggio (Figura 28).
- Mappa interattiva che mostra la posizione geografica dei migliori hotel corrispondenti ai criteri della ricerca (Figura 29).

Casi d'uso: Analisi delle Performance degli hotel in specifiche stagioni (es. hotel ottimi per l'estate ma carenti in inverno), analisi dell'apprezzamento degli hotel da parte di specifiche tipologie di viaggiatori, pianificazione di viaggi in base alle esigenze dell'utente.

🏆 Top Hotel: Winter, Spring, Summer, Autumn & Family, Couple, Business, Solo, Group, Leisure

I migliori hotel per la combinazione selezionata.

Hotel_Name	Season	Traveler_Type	Avg_Score	Review_Count	Nation
2 Hotel The Peninsula Paris	Autumn	Couple	9.88	13	France
3 Banks Mansion All Inclusive Hotel	Winter	Group	9.87	12	Netherlands
4 Le Narcisse Blanc Spa	Winter	Couple	9.87	18	France
6 Hotel Le Six	Summer	Couple	9.85	11	France
8 Best Western Premier Kaiserhof Wien	Autumn	Family	9.85	11	Austria
9 H tel de La Tamise Esprit de France	Winter	Couple	9.85	13	France
10 Hotel Spadari Al Duomo	Winter	Family	9.84	10	Italy
11 Pillows Anna van den Vondel Amsterdam	Summer	Leisure	9.84	10	Netherlands
12 H10 Casa Mimosa 4 Sup	Winter	Solo	9.84	10	Spain
14 The Wellesley Knightsbridge a Luxury Collection Hotel Lor	Winter	Leisure	9.83	12	United Kingdom

Figura 27: Lista degli hotel migliori in base alle stagioni e alle tipologie di viaggio selezionate

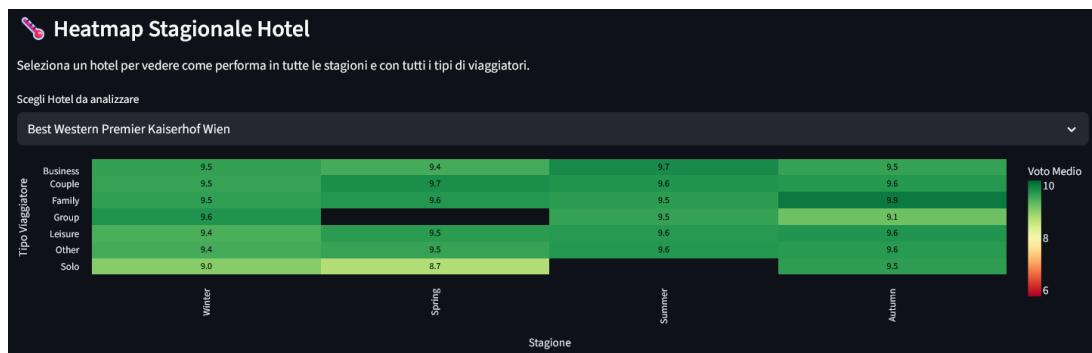


Figura 28: Heatmap Stagionale Hotel

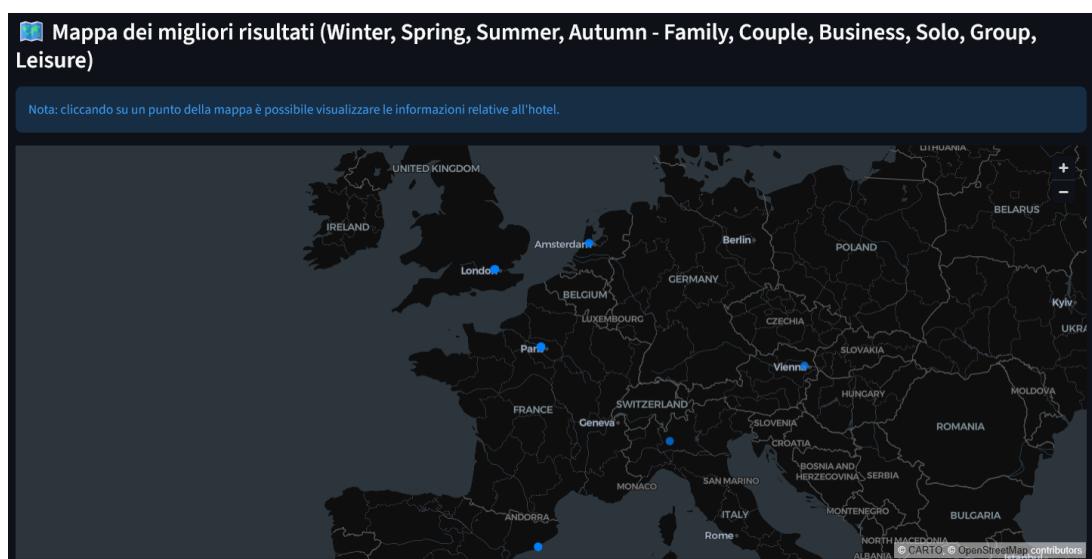


Figura 29: Mappa migliori hotel corrispondenti ai criteri della ricerca

3.9 Analisi Durata Soggiorno

Obiettivo: Analizzare la correlazione tra la durata del soggiorno (numero di notti) e il livello di soddisfazione dei clienti.



Figura 30: Query Analisi Durata Soggiorno

Logica Backend:

- Logica per l'estrazione del numero di notti dai tag delle recensioni:
 - input: tutte le recensioni, output: esplosione del dataset, producendo in output una riga per ogni elemento della lista dei tag di ogni recensione,
 - filtraggio di tutte le righe che presentano un tag nella forma "Stayed X nights",
 - estrazione del numero di notti (X),
 - categorizzazione del soggiorno fra: Short (1-3), Medium (4-7), Long (8+).
- Raggruppamento delle recensioni risultanti per hotel e categoria di soggiorno, con calcolo dei seguenti valori aggregati: punteggio medio, conteggio recensioni, durata media dei soggiorni.

Risultati:

- Viene analizzato lo **Score_Delta** delle diverse categorie di soggiorno, che è un **indicatore globale delle performance** di ogni categoria (Figura 31). Lo **Score_Delta** indica quanto il punteggio medio di ogni categoria di recensioni si discosta dalla media globale: ad esempio, se le recensioni di categoria "Long Stay" hanno un **delta negativo**, significa che, mediamente, i clienti che soggiornano a lungo negli hotel sono più **insoddisfatti** rispetto al gradimento medio globale.
- Vengono visualizzate le classifiche dei migliori hotel per ogni categoria di soggiorno, ordinate per punteggio medio (Figura 32).
- Viene visualizzato un grafico della distribuzione degli hotel in relazione alla durata media dei soggiorni dei loro clienti e al loro punteggio medio (Figura 33). Da questa rappresentazione è possibile valutare quali sono le durate dei soggiorni più frequenti e come sono correlate con la soddisfazione dei clienti.

Casi d'uso: Ottimizzazione delle offerte per soggiorni lunghi e corti, grazie a statistiche che mostrano se i soggiorni lunghi tendono ad avere recensioni peggiori o migliori.

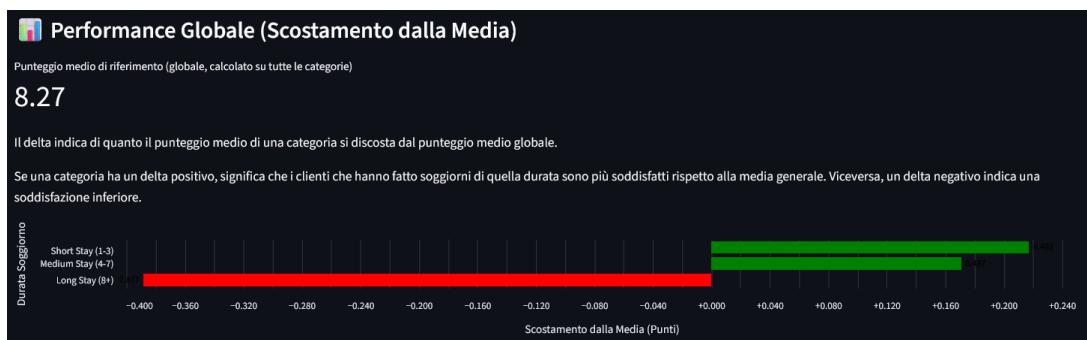


Figura 31: Performance Globale (Scostamento dalla Media)



Figura 32: Classifiche dei migliori hotel per ogni categoria di soggiorno

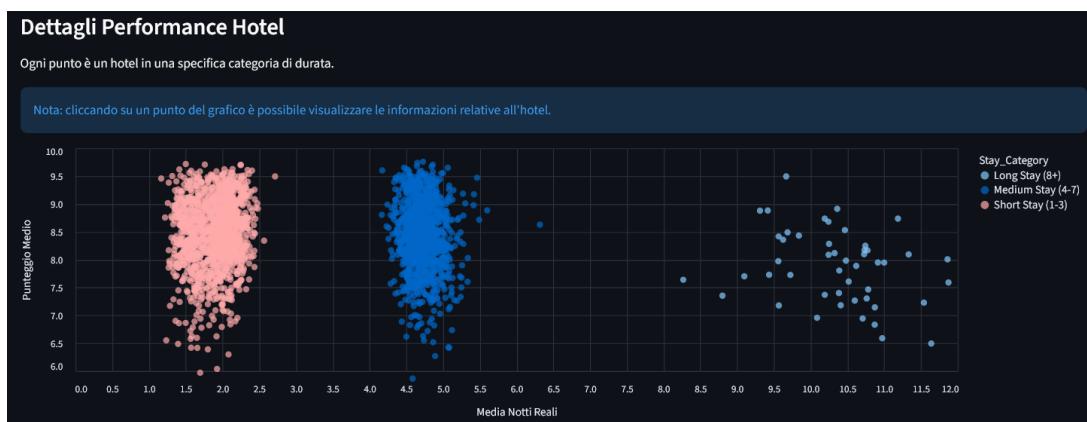


Figura 33: Grafico distribuzione hotel: punteggio medio vs durata soggiorno

3.10 Analisi Esperienza Recensore

Obiettivo: Valutare se il punteggio delle recensioni degli hotel cambia in base all'esperienza dei recensori (ad esempio se i recensori esperti sono più critici dei novizi).



Figura 34: Query Analisi Esperienza Recensore

Logica Backend:

- Categorizzazione recensioni in base all'esperienza del recensore, cioè in base al campo `Total_Number_of_Reviews_Reviewer_Has_Given`: se ha scritto meno di 5 recensioni allora è un "**Novizio**", se ha scritto fra 5 e 25 recensioni allora è un "**Intermedio**", altrimenti è un "**Esperto**".
- Aggregazione (con pivot su `Experience_Level`), raggruppando per Hotel e livello di esperienza del recensore, calcolando punteggio medio e numero di recensioni.
- Calcolo dell'`Experience_Gap` per ogni hotel, cioè la differenza tra il voto medio ottenuto dalle recensioni degli esperti e il voto medio ottenuto dalle recensioni dei novizi.

Risultati:

- Viene visualizzato il **Gap Medio** (Figura 35), cioè la differenza fra il voto medio assegnato dagli esperti e il voto medio assegnato dai novizi, calcolato su tutte le recensioni. Questo valore è la **metrica di riferimento** per valutare quanto in media i recensori esperti sono più critici dei novizi, o viceversa. Inoltre, vengono visualizzate le classifiche degli hotel con la maggior discrepanza (`Experience_Gap`) fra la valutazione degli esperti e quella dei novizi, sia in negativo (hotel criticati dagli esperti e apprezzati dai novizi), sia in positivo (hotel apprezzati dagli esperti e criticati dai novizi). Con questi confronti è possibile valutare quanto in media l'esperienza dei recensori impatta sulla valutazione degli hotel e quanto sono concordi o discordi le opinioni di recensori con diversi livelli di esperienza.
- Viene visualizzato un grafico della distribuzione degli hotel in relazione al voto ottenuto dai novizi e dagli esperti (Figura 36), che consente di valutare visivamente quanto sono frequenti gli hotel con alta o bassa discrepanza di voti.

Casi d'uso: Analisi della severità del voto in base dell'esperienza, in funzione di una ponderazione del peso delle recensioni in un sistema di ranking avanzato.

Gap Medio (Esperti - Novizi); se negativo, gli esperti sono mediamente più severi dei novizi
-0.05

👉 I più criticati dagli Esperti (Gap Negativo)

Hotel_Name	Novice_Avg_Score	Intermediate_Avg_Score	Expert_Avg_Score	Experience_Gap	Total_Analyzed_Reviews	Novice_Count	Intermediate_Count	Expert_Count
0 Hotel Les Bulles De Paris	8.44	8.24	6.67	-1.78	159	67	80	12
1 Best Western Blue Tower Hotel	7.40	7.30	6.19	-1.21	845	582	236	27
2 Mercure Paris Montmartre Sacré Coeur	8.27	8.46	7.09	-1.18	269	174	85	10
3 Hilton Diagonal Mar Barcelona	7.80	7.70	6.71	-1.09	140	80	50	10
4 Hilton London Euston	7.18	7.05	6.11	-1.07	470	337	122	11
5 Holiday Inn London West	8.04	7.89	6.98	-1.06	701	526	161	14
6 Hotel Sans Souci Wien	9.61	9.53	8.59	-1.03	235	120	98	17
7 Le Dokhans a Tribute Portfolio Hotel	8.12	8.44	7.10	-1.02	68	37	20	11
8 Ilunion Almirante	7.08	7.06	6.09	-0.98	264	127	121	16
9 Hotel Serhs Rivoli Rambla	8.01	8.09	7.04	-0.97	357	207	133	17

👉 I più apprezzati dagli Esperti (Gap Positivo)

Hotel_Name	Novice_Avg_Score	Intermediate_Avg_Score	Expert_Avg_Score	Experience_Gap	Total_Analyzed_Reviews	Novice_Count	Intermediate_Count	Expert_Count
838 Hotel Cavendish	6.39	6.47	7.49	1.10	920	627	272	21
837 Banke Hotel	8.48	8.20	9.53	1.05	159	86	61	12
836 Hotel Almara	7.84	7.70	8.88	1.04	195	114	71	10
835 Radisson Blu Champs Elysées Paris	7.24	7.47	8.18	0.94	152	87	55	10
834 Hilton London Green Park	7.21	7.38	8.14	0.93	484	346	126	12
833 Hotel Tiziano Park Vita Parcour Gruppo MiniHotels	7.77	8.17	8.67	0.90	61	27	24	10
832 Sloane Square Hotel	8.19	8.25	9.05	0.86	462	269	170	23
831 Grosvenor House Suites by Jumeirah Living	8.41	8.51	9.22	0.81	100	30	60	10
830 BEST WESTERN Maitrise Hotel Maida Vale	6.78	6.99	7.58	0.80	816	501	284	31
829 FourSide Hotel Vienna City Center	7.51	7.99	8.29	0.79	173	52	97	24

Figura 35: Gap Medio e classifiche degli hotel con la maggior discrepanza (Experience_Gap)

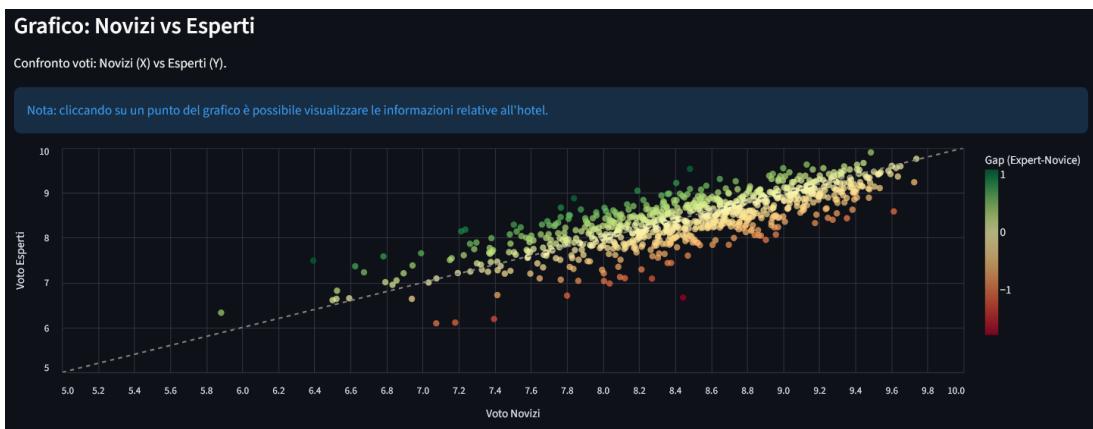


Figura 36: Grafico Novizi vs Esperti

4 Conclusioni Finali

Il progetto dimostra come l'utilizzo di **Spark** permetta di effettuare analisi complesse su un dataset di grandi dimensioni con **tempi di risposta contenuti**. L'architettura implementata garantisce **scalabilità orizzontale**, potendo gestire volumi di dati ben superiori a quello attuale senza modifiche al codice.

4.1 User Interface

L'**interfaccia grafica** realizzata con **Streamlit** offre un'esperienza utente semplice e funzionale, consentendo di eseguire le query on-demand e visualizzarne i risultati con facilità. Inoltre, l'utilizzo del sistema **web-app** rende il frontend dell'applicazione compatibile con diverse tipologie di dispositivo (Figura 37) senza richiedere l'installazione di alcun software e la rende accessibile da molteplici dispositivi contemporaneamente.

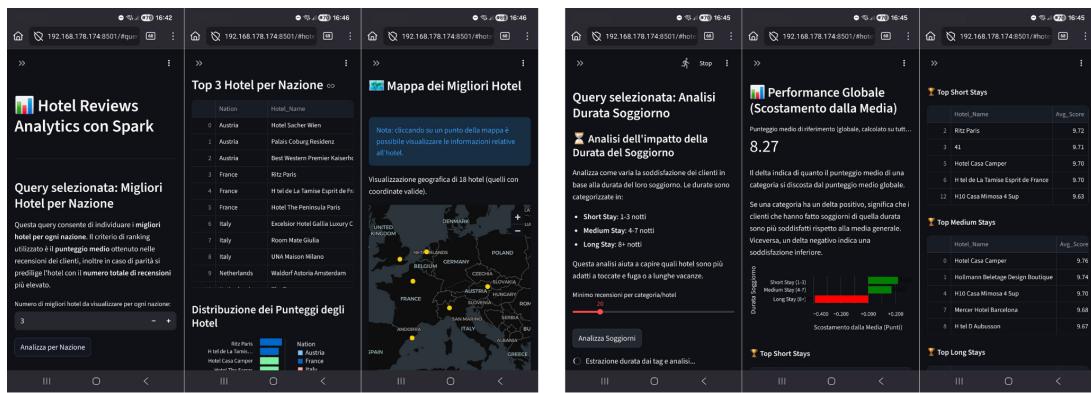


Figura 37: Esempi di come appare la UI della web-app quando vi si accede da smartphone (Android)

4.2 Analisi dei dati

Le query implementate esplorano diversi metodi di analisi dei dati, fra cui:

- **Analisi Descrittiva:** sintetizzare e riassumere i dati storici per descriverne le caratteristiche principali, utilizzando metriche chiave come media e deviazione standard, che offrono un'istantanea della distribuzione e delle tendenze centrali dei dati.
- **Analisi Diagnostica:** confrontare i dati, scoprire relazioni tra diverse informazioni (analisi di **correlazione**) e capire l'impatto di un fattore sull'altro (analisi di **regressione**), in modo da identificare le cause reali dei fenomeni osservati.
- **Analisi Predittiva:** prevedere risultati (**clustering/trend**), basandosi sull'uso di algoritmi che imparano dagli schemi presenti nei dati passati per proiettarli nel futuro.

4.3 Possibili Sviluppi Futuri

- **Analisi Prescrittiva:** raccomandare le azioni ottimali da intraprendere per raggiungere un risultato desiderato, utilizzando sistemi avanzati che simulano diversi scenari e valutano le opzioni migliori.
- **Analisi Inferenziale:** fare previsioni o generalizzazioni su una popolazione più ampia basandosi sull'analisi del campione di dati (test di ipotesi, intervalli di confidenza).

- **Analisi del Testo Avanzata:** implementare modelli NLP per Sentiment Analysis sulle recensioni testuali.
- **Streaming:** integrare Spark Streaming per elaborare recensioni in tempo reale.
- **Recommendation System:** sviluppare un sistema di raccomandazione basato sulla similarità utente-utente.